Certification Atlas Cisia

Etude de cas - Orientation et tri multimodal des demandeurs d'emploi par l'Intelligence Artificielle

Contents

01 Contexte, cadrage métier & analyse exploratoire (EDA)

02 Modélisation, sélection et politique de décision

03 Architecture applicative, industrialisation & MLOps

04 Bilan, démonstration & perspectives



Partie 1

Contexte, cadrage métier & analyse exploratoire (EDA)

4 Contexte

Je me présente

- Ingénieur calcul scientifique pendant 15 ans
- Expert technique en R&D innovation
- Un peu d'IA mais surtout sur des modèles de Computer Vision



Le cas d'usage

- Projet de certification Atlas CISIA
- Système d'aide à l'orientation et tri multimodal des demandeurs d'emploi



Bénéficiaires

- Conseillers qui doivent évaluer le risque de chômage de longue durée afin d'adapter le parcours usager au risque



Objectifs

- Aider les conseillers à orienter les usagers selon le délai potentiel de retour à l'emploi :
  - Classe 0 (< 6 m) : accompagnement standard
  - Classe 1 (< 12 m) : accompagnement ciblé
  - Classe 2 (> 12 m) : accompagnement renforcé



3 Cadrage métier



Outil d’aide à la décision

- Sujet traitant d’une prédiction de retour à l’emploi : qualification AI Act ➔ Système d'IA à « Haut Risque » (Annexe III, point 4)
- Le système **n'automatise pas la décision finale** : il fournit une recommandation fiable, objective et reproductible pour éclairer le conseiller



Asymétrie des coûts d’erreur

- L'erreur critique $2 \rightarrow 0$ (un usager en risque de chômage de longue durée classé en retour rapide) est la plus préjudiciable sur les plans humain et financier
- « Elle prive l'usager d'un accompagnement renforcé indispensable » et engage juridiquement l’administration



Latence

- La durée de traitement doit être compatible avec l’utilisation par un conseiller lors d’un entretien en face-à-face

Première exploration des données

Volumétrie & Qualité

- Dataset modéré : 2 500 dossiers, 10 variables
- Dataset multimodal : données tabulaires et textuelles
- Faible taux de valeurs manquantes ($< 5\%$)
- Pas de valeurs métier aberrantes sur l'âge, l'ancienneté

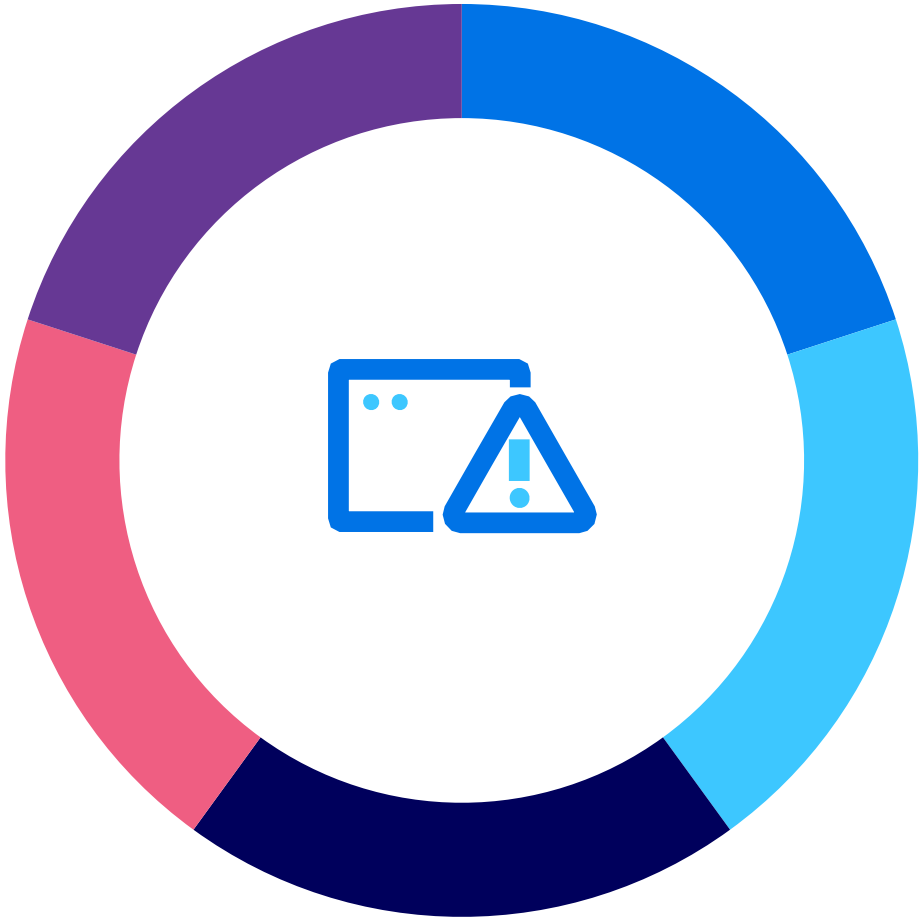
Variables catégorielles

- code_insee_commune :
  - $> 2\,400$ modalités
  - regroupement en départements (96 modalités)
  - ++ réduit la variance
  - ++ limiter les risques de réidentification
- code_rome_vise :
  - 50 modalités
  - Regroupement par lettre ➔11 modalités
  - Pas d'avantage clair (modalité la plus représentée 2,84%)

Variable textuelle

- 9 formulations récurrentes type « profils types »
- Encodage catégoriel direct en alternative à TF-IDF

Cadre réglementaire, éthique et analyse de biais



Variables sensibles : age et nationalite_hors_ue

Définition de l'**outcome favorable** : classe 0 ou 1 ➔ ne pas être en chômage longue durée

Disparate Impact (DI) < 0,8 pour :
50-59 ans, 60 ans et population hors UE

Effet d'intersectionnalité : aggravation marquée du DI sur le croisement « 50 ans et plus » ×« hors UE »

Réglementation :

- Interdiction absolue d'automatiser (Article 22 RGPD **+** AI Act européen qui classe les systèmes d'aide à l'emploi à haut risque**)**
- Matérialisation du risque de discrimination indirecte (Loi pour une République Numérique & Charte UE)

➔ **supervision humaine impérative**

Partie 2

Modélisation, sélection et politique de décision

Protocole expérimental & Scénarios (S1 à S8)

S1 Baseline complète TF-IDF

S2 Sans variable sensible

S3 Texte seul

S4 Tabulaire seul

S5 Texte en catégorielle

S6 Diplôme ordinal

S7 Ablation âge

S8 Ablation nationalité

X

M1 Régression Logistique

M2 Random Forest

M3 XGBoost

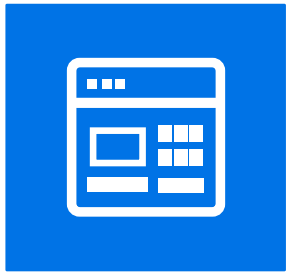
M4 LightGBM

- **Protocole** :
  - Séparation initiale étanche 80 % train / 20 % test (gelé)
  - Validation croisée StratifiedKFold(n_splits=5) sur le train
- **Exploration systématique** de 8 scénarios grâce à un pipeline utilisant des listes de variable paramétrables
- **4 scénarios structurants** définis dans le sujet + **2 scénarios** modifiant l'**encodage** d'une variable + **2 scénarios** évaluant **l'influence** de chaque **variable sensible**

X

- **Régression Logistique :** *modèle linéaire de référence simple, rapide et explicable*
- **Random Forest :** *Forêt d'arbres en parallèle. Faible variance, robuste au bruit, capture naturellement les non-linéarités et interactions*
- **XGBoost :** *Boosting d'arbres par niveau (level-wise). Robuste et progressif, mais calculs plus lourds.*
- **LightGBM :** *Boosting d'arbres par feuille (leaf-wise). Très rapide sur CPU, grande efficacité sur données mixtes (numériques + catégorielles à cardinalité modérée)*

Synthèse des résultats



Format de la variable synthèse TI-IDF vs catégoriel (S1 vs S5)

- Pb TF-IDF analyse la fréquence statistique de mots : un même mot peut être utilisé pour exprimer deux informations différentes (ex : compétences obsolètes ou compétences à jour)
- Scénario S5 variables catégorielles :
  - F1 macro ↗ (0,699 → 0,704) / le recall classe 2 ↗ (0,597 → 0,602) / l'erreur critique ↘ (11,3 % → 10,8 %)



Scenario Texte seul “synthese_entretien” (S3)

- La variable texte ne suffit pas à modéliser la complexité de la trajectoire de retour à l’emploi
- Le taux d'erreur critique 2→0 explose à 19,0 % en moyenne avec une instabilité entre les folds (28,8 % au maximum).
- Les données tabulaires (parcours, métier, diplôme) restent le socle prédictif indispensable.



Les scenarios éthiques (S2, S8, S9)

- **Sans variable sensible** (S2) : Effondrement prédictif (Tous les modèles chutent sous 0,645 de F1 macro), explosion du risque humain (taux d'erreur critique 2→0 > 20%
- **Ablation de l’âge** (S7) : supprimer l'âge effondre le F1 macro de 0,704 à 0,625 (−0,079) et fait bondir l'erreur critique de 10,8 % à 16,6 % (+5,8 pts). Dégradation brutale > 53 ans
- **Ablation de la nationalité** (S8) : supprimer la nationalité entraîne une baisse plus modérée du F1 (0,704 → 0,673) et une hausse d'erreur critique de 10,8% à 13,2%. Option d'atténuation éthique à étudier

Optimisation des hyperparamètres & Arbitrage final

- Scénarios retenus - **S5 LightGBM, S5 Random Forest et S5 Régression logistique**:
  - 3 **architectures différentes :**
    - 1 modèle linéaire pour une référence interprétable
    - 1 méthode d 'ensembles d'arbres indépendants
    - 1 méthode d'ensemble d'arbres construits par boosting
  - La régression logistique augmente le taux d'erreurs critiques
  - LightGBM équilibré (meilleur F1macro) vs Random Forest (meilleur recall classe 2)

- Méthode d'optimisation retenue : **GridSearchCV** :
  - simple et reproductible sur un volume de test maîtrisé pour de la comparaison de scénarios
  - Optuna ou RandomizedSearch plus précis mais moins répétables

- Scénario retenu - **S5 LightGBM** :
  - Random Forest améliore le recall de la classe 2 mais fait chuter le DI (<< 0.7 pour les 2 variables sensibles)
  - LightGBM améliore la latence (x2.6)
  - Taux d'erreur critique identique pour les 2 scénarios (10.8%)

Évaluation finale sur jeu de test indépendant & Explicabilité SHAP

- **Le modèle généralise correctement** (-> pas de surapprentissage) :
  F1-score macro : Test 0,7218 (contre 0,6955 en validation CV)
  Accuracy globale : 74,0%
  Taux d'erreur critique 2→0 : 7,8% (stable par rapport à la CV – 10,78%)
- Équilibre par classe :
  Classe 0 (Rapide) : Précision 78% | Rappel 75% | F1=0,77
  Classe 1 (Intermédiaire) : Précision 71% | Rappel 80% | F1=0,75
  Classe 2 (Longue durée) : Précision 76% | Rappel 57% | F1=0,65
- L'**analyse SHAP** montre que la prédiction du modèle résulte du croisement de l'ancienneté, des freins exprimés dans la synthèse d'entretien, du niveau de diplôme et de l'âge
- Aide à justifier pour le conseiller et l'usager un droit à **l'explication transparente** du score d'aide à la décision (AI Act Art. 13 & RGPD Art. 22)
- Effet **non-linéaire de l'âge** :
  - entre 18 et 53 ans l'âge a un effet protecteur ou neutre (contributions SHAP négatives de −0,572 à −0,284)
  - au-delà de 53 ans l'impact bascule brutalement à +1,640 vers la classe 2
- Rôle **modéré de la nationalité hors UE** : Contribution SHAP moyenne très faible : +0,059 pour Hors UE (vs −0,008 pour UE)

Audit éthique par sous-groupe (Test set)

- Relecture métier du Disparate Impact (EDA) :
  - Le calcul effectué considérait les classes 0 et 1 comme favorables
  - D'un point de vue métier, orienter un usager vers la Classe 2 lui accorde un accompagnement renforcé
  - Le modèle ne crée pas de biais algorithmique ➔reflète les difficultés structurelles existantes du marché de l'emploi après 50 ans
- Protection confirmée des publics sensibles :
  - Seniors (60 ans et plus) : rappel Classe 2 = 81,2 % (le plus élevé du modèle), erreur critique 2→0 = 0,0 % (0 senior en risque abandonné en autonomie), prédiction conforme au réel (44,4% vs 44,4%)
  - Usagers hors Union Européenne : rappel Classe 2 = 75,0 %, erreur critique 2→0v= 0,0 %
- Alerte éthique : rupture chez les moins de 50 ans
  - risque de « perte de chance » chez les moins de 50 ans
  - Les rares erreurs critiques 2→0 restantes se concentrent exclusivement sur les tranches actives intermédiaires (18–29 ans et 40–49 ans, 2 cas chacune)
  - Taux de base historique faible en classe 2 pour ces tranches d'âge → tendance statistique du modèle à privilégier l'autonomie
- Réponse opérationnelle :
  - Ce risque impose la mise en place d'un filet de sécurité post-prédiction (abstention et revue humaine renforcée)

Filet de sécurité & Stratégie de fallback (seuils opérationnels)

- Objectif métier : intercepter le risque « perte de chance » (2 ➔ 0) et gérer l'incertitude du modèle sans surcharger les conseillers
- Mise en place de **règles de seuils opérationnels** (p est le tableau des probabilités obtenues, p0 est la probabilité de la classe 0) :

Statut	Règle	Action
Abstention	max(p) < 0,60	Décision humaine
Revue renforcée	Classe 0 et 0,60 ≤ p0 < 0,80	Vérification renforcée
Acceptation assistée	p0 ≥ 0,80 ou max(p) ≥ 0,60 pour classe 1/2	Aide à la décision

- Les règles choisies permettent
  - d'intercepter 42,9% des erreurs critiques 2 ⟶ 0 (3 sur 7) sur le jeu de test (51,3% sur le train) , réduisant le taux d'erreur résiduel à 4,4% (contre 7,8% sans filet)
  - ede ne soumettre que 19,2% des dossiers à une revue partielle ou complète par les conseillers (18% pour le train), sous le plafond opérationnel de 20%

Partie 3

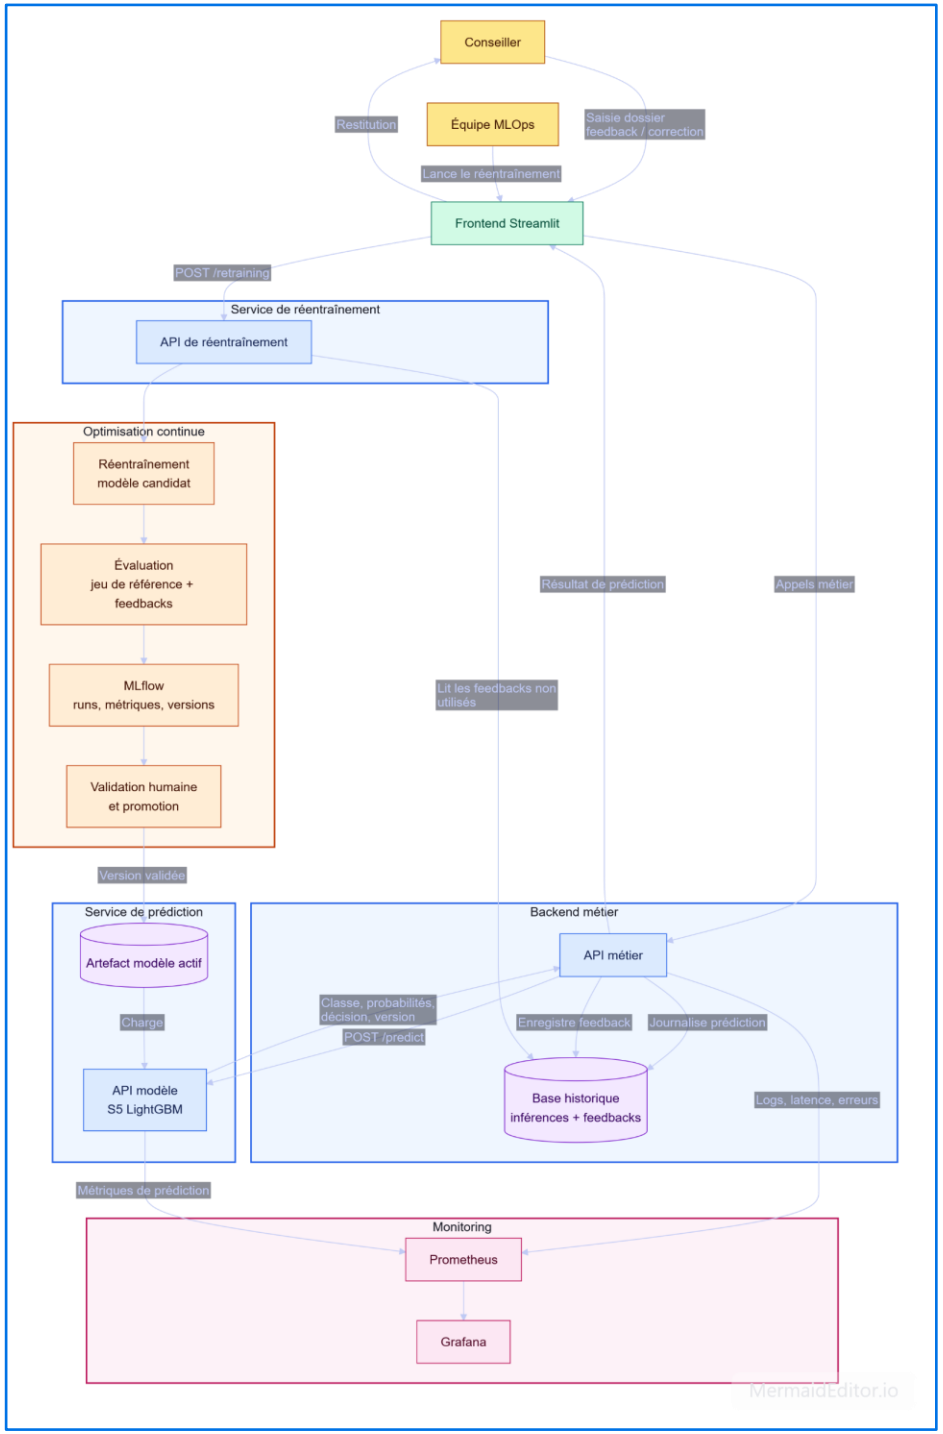
Architecture applicative, Industrialisation & MLOps

Architecture microservices & flux de données

- L'architecture est basée sur 5 composants :
  - Un **Frontend Streamlit** qui est l'UI utilisée à la fois par les conseillers pour demander une prédiction, saisir des dossiers ou enregistrer un feedback, et par l'équipe MlOps pour le réentrainement et la supervision du système
  - Un **service Backend Métier API** qui assure la validation des informations saisies, applique les transformations avant appel du modèle et implémente les règles du filet de sécurité pour afficher une recommandation et non des résultats bruts
  - Un **service Model API** qui réalise l'inférence
  - Un **service Retraining API** dédié aux opérations de réentrainement pour l'amélioration continue par l'équipe MlOps
  - Des **services de monitoring** Prometheus et Grafana permettant d'enregistrer les métriques de chaque service (disponibilité, latence, erreurs http et répartition des prédictions) et de les intégrer dans un tableau de suivi

Schéma d'architecture

- Les services utilisent le framework API et des modèles de données Pydantic
- Les **règles métier** sont découplées du modèle
- La **traçabilité** est assurée par un identifiant de requête unique
- L'architecture permet de tester un modèle candidat **sans arrêter le système** et **de revenir rapidement à une version antérieure** en modifiant le numéro de version du modèle utilisé dans un fichier dédié



Boucle de feedback & Réentraînement contrôlé

Persistance & Traçabilité :

- **Base relationnelle SQLite** métier (backend_metier.db) : tables « predictions » et « feedbacks » reliées par request_id
- **Registre local d'artefacts** (Models/): stockage des modèles sérialisés (.joblib) et de leurs métadonnées (.json)
- **Pointeur de release** (active_model.json) : permet une promotion de la nouvelle version et un rollback rapide

Workflow de réentrainement :

- Agrégation des **feedbacks** non utilisés avec le dataset d'entrainement
- Entrainement d'un **candidat** (pipeline_candidate.joblib)
- **Evaluation comparative sur jeu de référence gelé** (rapport de comparaison dans « promotion_decision.json »)

Gouvernance & Promotion humaine :

- Stratégie **hybride** :
  - Plancher absolu F1 ≥ 0,65 (sécurité minimale garantissant l'équilibre sur les 3 classes)
  - Gain relatif minimal > à la variation statistique de 0,018
  - Tolérance de 1% sur l'erreur critique (ne pas augmenter le nombre de dossier non détecté 2 ➔ 0)
- **Pas de promotion automatique** : les équipes MLOps modifient active_model.json ce qui renforce le contrôle humain lié au besoin de supervision d'un système IA à haut risque

Observabilité & Monitoring

Traçabilité réentrainement via **MlFlow :**

- **Journalisation** automatique des runs de réentrainement et d'évaluation (mlflow.log_params & mlflow.log_metrics)
- **Métriques** enregistrées : accuracy, **F1 macro**, **nombre d'erreurs critiques**, **taux d'erreur critique**
- **Métadonnées** enregistrées : nom du modèle, scénario d'entrainement, version du modèle, hyperparamètres LightGBM
- **Génération d'un rapport (json)** contenant les recommandations exposées dans l'interface Streamlit

Monitoring du système (Prometheus + Grafana) :

- Collecte des métriques techniques & opérationnelles toutes les 5s
- Dashboard Grafana exposant :
  - **Disponibilité** des 3 services (panneaux de statut avec alerte visuelle)
  - **Qualité de service** : latence p95 et la détection d'erreurs 502/503 (séries temporelles)
  - Signal métier : **répartition des classes prédites** (bar chart) afin de détecter une éventuelle dérive des prédictions

Packaging Docker, Pipeline CI/CD & Orchestration

Conteneurisation :

- **Réduction de la taille des images** :
  - multi-stage builds
  - modèle injecté via le montage du volume Models/
- Isolation des **utilisateurs non root**
- Ajout de **dépendances système** (libgomp1 pour OpenMP)

Pipeline CI/CD :

- Automatisation via **GitHub Actions** (ci.yml)
- Workflow de développement :
  - branche feature : tests ➔ build ➔ Pull Request
  - merge vers master : pubis
- Publication des images dans GitHub Container registry

Déploiement et orchestration :

- Orchestration des services via Docker Compose
- Simulation du déploiement en production : docker-compose.prod.yml, à partir des images taguées par le SHA du commit Git

Partie 4

Démonstration, Bilan & Perspectives

Démo

- Animation
    2. Saisie d'un dossier candidat dans l'interface Streamlit ➔ Prédiction et affichage du statut de revue ➔ saisie de la décision finale.
    - 2. Enregistrement d'un feedback de correction par un conseiller.
    - 2. Déclenchement du réentraînement depuis l'espace MLOps et consultation du rapport de recommandation.
    - 2. Visualisation du run dans MLflow et des métriques dans Grafana.

Bilan du système, réserves opérationnelles et perspectives (1)

1. Bilan du système : une solution robuste, sécurisée et auditable

- Aide à la décision opérationnelle :
  - Inférence ultra-rapide (~0,03 ms/dossier)
  - parfaitement fluide et transparente lors d'un entretien face-à-face conseiller/usager
- Architecture découplée & robuste :
  - Séparation stricte des responsabilités (API Modèle / API Métier / API Réentraînement)
  - contrats d'entrées/sorties stricts validés par Pydantic
  - conteneurisation Docker
- Supervision & auditabilité continue :
  - Traçabilité complète des décisions (identifiant request_id, versioning active_model.json, stockage SQLite des prédictions/feedbacks)
  - métriques Prometheus/Grafana
- MLOps contrôlé sans rupture :
  - Boucle de réentraînement continue sur feedbacks avec comparaison rigoureuse Candidat vs Prod sur jeu gelé
  - Sans interruption de service et sans promotion aveugle

Bilan du système, réserves opérationnelles et perspectives (2)

2. Réserves opérationnelles & Points de vigilance :

- **Validation juridique et conformité éthique** : homologation formelle par le DPO et le pôle juridique (système classé à haut risque sous l'AI Act Annexe III, contrôle strict de la non-discrimination indirecte et du RGPD Art. 22)
- Qualité de la variable **synthese_entretien** :
  - Actuellement restreinte à 9 libellés génériques limitant la finesse du signal
  - Préconisations :
    - Affiner la grille de saisie, séparer les composantes (freins périphériques vs compétences)
    - Choix d'un vocabulaire séparé positif ou négatif pour TF-IDF
    - Explorer du texte libre via un modèle d'embedding
    - Rendre la complétion du champ obligatoire par le conseiller ➔ éviter les manquants

Bilan du système, réserves opérationnelles et perspectives (3)

3. Perspectives & Évolutions de la feuille de route :

- Sécurité & Gouvernance d'accès : Intégration d'une couche d'authentification (OAuth2 / JWT / RBAC) pour restreindre les opérations de réentraînement et les promotions aux seuls profils MLOps habilités
- Détection active de dérive (Drift) : Automatisation du suivi du Data Drift (PSI, Kolmogorov-Smirnov) et du Concept Drift au fil de l'accumulation des feedbacks
- Audits d'équité approfondis : Industrialisation d'audits périodiques intégrant des analyses intersectionnelles (croisement systématique âge × nationalité)



Questions

Thank you!

Atos is a registered trademark of Atos SE. April 2024. © 2024 Atos.
Confidential information owned by Atos, to be used by the recipient only.
This document, or any part of it, may not be reproduced, copied, circulated
and/or distributed nor quoted without prior written approval from Atos.